

표준학개론 기말 텀페이퍼 - 프로포절

표준학개론 (INTRODUCTION TO STANDARDS) 기말 텀페이퍼 — 프로포절

국제 메타데이터 표준을 통합한 LLM 기반 그래프 증강 추천시스템

**Standard-Aware LLM Graph Augmentation for Recommendation:
A Quantitative Trade-off Analysis between Recommendation
Performance and Metadata Standard Compliance**

— 멀티모달 증강을 통한 추천시스템 Cold-Start 문제 해결을 위한 선행 연구 —

1. 연구 배경 및 동기

추천시스템에서 데이터 희소성은 신규/저활동 사용자·아이템에 대한 추천을 어렵게 만드는 cold-start 문제의 근원이다. 최근 Wei et al.(WSDM '24)이 제안한 **LLMRec**은 GPT-3.5에게 사용자 시청 이력과 아이템 정보를 입력하여 (i) 잠재적 user-item 상호작용 edge, (ii) item 속성(감독·국가·언어), (iii) user profile을 자연어로 생성·증강함으로써 GNN 기반 추천기의 학습 신호를 풍부화하는 SoTA 접근법이다.

그러나 LLMRec이 LLM에게 자유 텍스트 형태로 메타데이터를 생성하도록 지시하는 설계는 표준학적 관점에서 구조적 문제를 노정한다. 본 연구의 사전 데이터 분석(LLMRec 공개 augmented_attribute_dict, n=17,366) 결과 다음 세 가지 표준 미준수 패턴이 확인된다.

패턴	정량 증거
표면 분산	동일 미국이 'USA'(8,091건) / 'United States'(1,995건) / 'America' 등 1,166개 토큰으로 분산 (ISO 3166 표준은 ~250개)
LLM 환각	'country' 단어가 국가명 자리에 835건 등장 — placeholder 환각
컬럼 시프트	'USA'(국가명)가 언어 자리에 492건 등장 — 자유 텍스트 파싱 오류




Figure 1. LLMRec augmented data의 country 필드 토큰 분포 (사전 데이터 분석)

Figure 1은 본 연구가 사전 분석한 LLMRec augmented data의 country 필드 토큰 분포이다. 좌측의 빨간색 막대('country' 835건)는 LLM 환각이며, 우측은 본 연구가 적용할 ISO 3166-1 alpha-2 정규화의 예상 효과를 시각화한다. 동일 의미 토큰이 단일 표준 코드로 응축될 수 있는 가능성이 정량적으로 확인된다.

```

419: {0: '[419] Breathless (À bout de souffle) (1960), Crime|Drama|Romance ',
1: ' Jean-Luc Godard',
2: 'France'},
420: {0: 'Baby, The (1973)', 1: 'USA', 2: 'English'},
421: {0: 'D2: The Mighty Ducks (1994)', 1: 'USA', 2: 'English'},
422: {0: 'Major League: Back to the Minors (1998)', 1: 'USA', 2: 'English'},
423: {0: 'Billy Madison (1995)', 1: 'USA', 2: 'English'},
424: {0: 'Andre (1994)', 1: 'USA', 2: 'English'},
425: {0: 'Alien from L.A. (1988)', 1: 'USA', 2: 'English'},
426: {0: 'Thin Man Goes Home, The (1945)', 1: 'USA', 2: 'English'},
427: {0: 'Aguirre: The Wrath of God (Aguirre, der Zorn Gottes) (1972)',
1: 'West Germany',
2: 'German'},
428: {0: 'Hellbound: Hellraiser II (1988)', 1: 'UK', 2: 'English'},
429: {0: 'Lady in Red, The (1979)', 1: 'USA', 2: 'English'},
430: {0: 'Asfalto (2000)', 1: 'Spain', 2: 'Spanish'},
431: {0: 'Candy (2006)', 1: 'Australia', 2: 'English'},
432: {0: 'Horse Feathers (1932)', 1: 'USA', 2: 'English'},
433: {0: 'Back Stage (2000)', 1: 'France', 2: 'French'},
434: {0: 'Lions For Lambs (2007)', 1: 'USA', 2: 'English'},
435: {0: 'Guillermo del Toro', 1: 'Spain', 2: 'Spanish'},
436: {0: 'Joe Johnston', 1: 'USA', 2: 'English'},
437: {0: 'Ron Clements', 1: 'USA', 2: 'English'},
438: {0: 'Peter Farrelly', 1: 'USA', 2: 'English'},
439: {0: 'Juan Carlos Fresnadillo', 1: 'Spain', 2: 'Spanish'},
440: {0: 'Xavier Gens', 1: 'France', 2: 'English'},
441: {0: 'Morgan Freeman', 1: 'USA', 2: 'English'},
442: {0: 'Dennis Dugan', 1: 'USA', 2: 'English'},
443: {0: 'John Ford', 1: 'USA', 2: 'English'},
444: {0: 'Julie Davis', 1: 'USA', 2: 'English'},
445: {0: 'Clint Eastwood', 1: 'USA', 2: 'English'},
446: {0: 'Chris Menges', 1: 'USA', 2: 'English'},
447: {0: 'Michael Hoffman', 1: 'USA', 2: 'English'},
448: {0: 'Shohei Imamura', 1: 'Japan', 2: 'Japanese'},
450: {0: 'Burglar (1987)', 1: 'USA', 2: 'English'},
451: {0: 'Blow (2001)', 1: 'USA', 2: 'English'},
452: {0: 'Down to You (2000)', 1: 'USA', 2: 'English'},
453: {0: 'Skins (2002)', 1: 'USA', 2: 'English'},
454: {0: 'Tag: The Assassination Game (a.k.a. Everybody Gets It in the End) (1982)',
1: 'USA',

```

Reference: LLMRec 공식 repository 제공 augmented item attribute dictionary 스크린샷. 'USA', 'United States', 'UK', 'France' 등 비표준 자유 텍스트가 그대로 저장된 상태가 확인된다.

이러한 표준 미준수는 임베딩 공간에서 의미적으로 동일한 속성이 분산되어 cold-start 일반화 성능을 저해할 가능성이 있으며, 외부 시스템 간 메타데이터 상호운용성도 확보되지 않는다. 본 연구는 schema.org/Movie, ISO 3166-1 alpha-2(국가), BCP 47(언어), ISO 8601(날짜) 등 국제 표준을 LLMRec 파이프라인에 명시적으로 통합하고, **추천 성능과 표준 적합성 간의 트레이드오프를 정량적으로 분석**할 것이다. 본 연구는 표준 준수가 데이터 기반 AI 시스템의 성능과 상호운용성에 미치는 영향을 실증적으로 규명하는 표준학적 사례 연구로 자리매김한다.

2. 연구 목표 및 연구 질문

본 연구는 다음 세 가지 연구 질문(RQ)에 답하는 것을 목표로 한다.

- **RQ1.** LLM 기반 데이터 증강 결과에 국제 메타데이터 표준(schema.org/Movie, ISO 639/3166)을 적용하면 추천 성능(Recall@K, NDCG@K)에 어떤 영향을 미치는가?

- **RQ2.** 표준 적용의 효과는 시나리오별로 어떻게 달라지는가? 특히 long-tail 아이템, 희소 국가·언어 카테고리 등 표준이 효과를 발휘할 수 있는 특정 조건을 식별한다.
- **RQ3.** 추천 성능과 표준 적합성·상호운용성 간의 트레이드오프를 어떻게 정량화하고 평가할 수 있는가?

본 연구는 단순한 성능 향상 주장이 아니라, 표준학적 관점에서 정당화 가능한 트레이드오프 분석 결과를 제시하는 것을 목표로 한다.

3. 연구 내용 및 방법

3.1 베이스라인 재현

LLMRec 공식 공개 코드(github.com/HKUDS/LLMRec) 와 GPT-3.5-turbo로 사전 생성된 augmented dataset을 활용하여 Netflix 데이터셋에서 베이스라인을 재현한다. 저자가 공개한 augmented dataset(LLM이 사전 생성한 메타데이터)을 그대로 활용함으로써 OpenAI API 호출 비용을 최소화한다. 1차 목표 성능은 논문에 보고된 Recall@20 = 0.0829 수준으로 설정한다.

3.2 Standard-Aware 통합 — 2단계 분리

본 연구는 표준 통합을 (A) Prompt-time 설계 와 (B) Post-hoc 정규화 두 단계로 분리한다.




Figure 1: The LLMRec framework: (1) Three types of data augmentation strategies: i) augmenting user-item interactions; ii) enhancing item attributes, and iii) user profiling. (2) Augmented training with and denoised data robustification mechanism.

Figure 2. LLMRec 원본 프레임워크 — (1) *u-i edge* 증강, (2) *item* 속성 증강, (3) *user profile* 증강의 3가지 LLM 기반 증강 전략 + *denoising*. 본 연구는 이 파이프라인 위에 표준 통합 모듈을 추가할 것이다.

Figure B. Vanilla vs Standard-Aware 파이프라인 비교




Figure 3. Vanilla LLMRec vs 본 연구의 Standard-Aware 파이프라인

Stage A. Standard-Aware Prompting 설계 (정성)

LLMRec의 자유 텍스트 프롬프트(P_I, P_U, P_{UI})를 schema.org/Movie JSON-LD 어휘와 ISO 표준 코드 체계에 정합하도록 재설계한 템플릿을 제시한다. 핵심 설계 원칙: - 출력 포맷을 JSON-LD with @context: schema.org/Movie로 강제 - countryOfOrigin: ISO 3166-1 alpha-2, inLanguage: BCP 47, datePublished: ISO 8601, contentRating: MPAA, genre: [schema.org / EIDR vocabulary](https://schema.org/EIDR_vocabulary) - 미상 시 null 강제 → LLM 환각 차단

본 토크페이퍼 범위에서는 LLM 재호출을 수행하지 않으며 (OpenAI API 비용 회피, 일정 단축), 본 설계 자산은 졸업논문 단계의 sLLM(Llama-3-8B) 재증강 실험에 재사용될 예정이다.

Stage B. 후처리 정규화 모듈 (정량 실험의 핵심)

LLMRec이 생성한 자유 텍스트를 ISO 표준 코드로 매핑하는 정규화 모듈(약 150줄 규모)을 구현한다.

- pycountry 라이브러리 lookup (ISO 3166, ISO 639)
- 별칭 사전 (USA/United States/America → US; UK/United Kingdom → GB; Soviet Union → RU 등)
- 컬럼 시프트 거부 휴리스틱 (국가 코드가 언어 자리에 등장 시 invalid 처리)
- 환각 토큰 거부 (country, language, n/a, unknown 등 placeholder)

Centroid 기반 임베딩 갱신

표준 적합성의 임베딩 공간 효과를 추가 LLM 호출 없이 시뮬레이션하기 위해, 동일 표준 코드(예: 'US')로 정규화된 모든 아이템의 기존 ada-002 임베딩의 centroid를 계산하여 그룹 전체에 동일하게 할당한다. 이는 prompt-time 표준 통합의 상한선 근사로 해석될 수 있으며, 본 토크페이퍼의 정량 실험 핵심 방법론이다.

3.3 평가 프레임워크 — 3축

본 연구는 단일 성능 지표가 아닌 다축 평가 프레임워크를 도입하여 표준 적용의 다면적 효과를 측정한다.

평가 축	지표	측정 목적
추천 성능	R@10/20/50, N@10/20/50, P@20	LLMRec 논문 동일 프로토콜 — 표준 적용 시 성능 변화 정량화
표준 적합성	Standard Compliance Rate (SCR) — 본 연구 제안	LLM 출력의 국제 표준 부합 비율
상호운용성	Interoperability Score (IS) — 본 연구 제안	외부 시스템 메타데이터 호환성

SCR_field = (해당 필드가 이미 표준 표기인 아이템 수) / (전체 아이템 수) **IS** = (4개 schema.org 필수 필드가 모두 정규화 가능한 아이템의 비율)

추가로 long-tail 시나리오 검증을 위해 학습 인터랙션 빈도 기준으로 cold/warm 아이템을 분리하여 별도 Recall@20을 측정한다.

4. 표준학적 의미

본 연구는 다음 세 가지 측면에서 표준학 영역에 기여한다.

첫째, schema.org/Movie, ISO 639, ISO 3166 등 다층적 국제 메타데이터 표준이 데이터 기반 AI 시스템에 어떻게 통합 가능한지 실증한다. 표준학에서 표준은 사후 정리(data cleaning)의 도구로 흔히 인식되어 왔으나, 본 연구는 LLM이 데이터를 생성하는 시점부터 표준이 개입하는 standard-compliant data generation 접근의 설계 청사진(Stage A)과 후처리 효과 실증(Stage B)을 함께 제시한다.

둘째, 표준 준수가 시스템 성능에 미치는 영향을 정량적으로 측정함으로써, 표준 적용의 비용-편익을 실증적으로 분석한다. 표준학 연구에서 표준 준수는 단기적 성능보다 장기적 상호운용성·확장성·생태계 호환성에 가치를 두는 것이 일반적이며, 본 연구는 이러한 트레이드오프를 AI 시스템 영역에서 정량화하는 사례 연구가 될 것이다.

셋째, LLM 시대 추천시스템 메타데이터 품질을 평가하기 위한 새로운 지표 (**Standard Compliance Rate, Interoperability Score**)를 제안한다. 이는 향후 LLM 기반 데이터 증강 기법의 표준 적합성을 평가하기 위한 프레임워크로 확장 가능하다.

5. 졸업논문과의 연계성

본 프로젝트는 석사 졸업논문 「멀티모달 증강을 통한 추천시스템 Cold Start 문제 해결」의 선행 연구로 명확히 위치한다. 졸업논문은 이미지·텍스트·메타데이터를 결합한 cross-modal augmentation 기법을 제안할 예정이며, 본 프로젝트에서 검증한 표준 기반 메타데이터 정규화 모듈은 졸업논문의 텍스트 메타데이터 처리 단계로 직접 통합된다.

특히 본 연구에서 제안하는 Standard-Aware Prompting 템플릿(Stage A)과 정규화 모듈(Stage B)은 졸업논문에서 다음과 같이 확장된다:

1. **Prompt-time 표준 통합 실증** — sLLM(Llama-3-8B) 파인튜닝으로 실제 LLM 출력 수준 검증
2. **Cold-start 직접 검증** — ML-10M의 더 dense한 split + attribute-aware backbone(VBPR/MMGCN)으로 확장
3. **다 backbone 모델 무관성 검증** — LATTICE, MMSSL, MICRO 등에 표준 통합 모듈 적용
4. **EIDR/MPAA/ISO 26324 추가 표준 통합** — contentRating, duration, genre, identifier 필드까지 확장

6. 활용 자원

- **LLMRec 공식 코드 및 augmented dataset:** Netflix 데이터셋과 GPT-3.5-turbo로 사전 생성된 메타데이터가 모두 공개되어 있어, 베이스라인 재현 시 OpenAI API 비용이 거의 발생하지 않음
- **LLMRec 재현성 연구** (nickolat/LLMRec_reproducibility, RecSys 2025): 환경 설정 및 데이터 split 보조 자료
- **연구자 보유 sLLM 파인튜닝 코드:** 졸업논문 단계 prompt-time 검증용 (Llama-3-8B, Polyglot-Ko)
- **국제 표준 자원:** pycountry 라이브러리(ISO 3166, ISO 639), schema.org Movie vocabulary, EIDR 등록 데이터, MPAA 등 각국 등급 분류 공식 정의
- **하드웨어:** NVIDIA RTX PRO 6000 Blackwell (98GB VRAM) — LLMRec 학습 시간 $\approx$ 30초/실험

7. 연구 일정

본 프로젝트는 2026년 1학기 종강 시점(6월 말)을 마감으로 하여, 다음과 같은 단계로 수행한다.

시기	주요 작업	세부 내용 및 산출물
5월 2주	환경 구축 및 베이스라인 재현	LLMRec 공식 repo clone, Netflix 데이터셋 환경 구축, 공개 augmented dataset으로 베이스라인 재현 (목표 $R@20=0.0829$)
5월 3주	Standard-Aware Prompting 설계 문서화	schema.org/Movie 스키마 기반 P_I, P_U, P_UI 프롬프트 템플릿 작성 (LLM 재호출 없음)
5월 4주	표준 정규화 모듈 + 임베딩 생성	ISO 3166 / BCP 47 / MPAA 매핑 사전 구축, pycountry 활용 정규화 모듈 (~150줄), Centroid 기반 임베딩 갱신
6월 1주	실험 수행	Vanilla LLMRec vs Standard-Aware LLMRec 비교 ($R@K$, $N@K$, $P@20$), 정규화 효과 ablation
6월 2주	결과 분석 및 정성 평가	성능 트레이드오프 분석, Standard Compliance Rate / Interoperability Score 측정, 시각화
6월 3주	최종 보고서 및 발표 준비	기말 텀페이퍼 작성, 발표 자료 제작, 졸업논문 연계 방안 정리

8. 예상 한계 및 대응 방안

본 연구는 다음과 같은 한계를 가질 수 있으며, 이에 대한 대응 방안을 사전에 준비한다.

첫째, 표준 적용 시 LLM 임베딩의 자연어 표현력이 일부 손실되어 전체 추천 성능(Recall, NDCG)이 vanilla LLMRec 대비 동등 수준 또는 소폭 하락할 가능성이 존재한다. 이는 본 연구의 핵심 메시지가 단순한 성능 향상이 아닌 트레이드오프 분석에 있음을 명확히 함으로써 대응한다 — 결과가 어떤 방향으로 나오든 표준학적 해석이 가능한 연구 설계를 채택한다.

둘째, schema.org/Movie 스키마는 50개 이상의 필드를 포함하므로, 본 연구에서는 LLMRec 공개 데이터에 가용한 핵심 필드(director, countryOfOrigin, inLanguage, datePublished)로 범위를 한정한다. contentRating, duration, genre 등 결락 필드는 졸업논문 단계 MovieLens 확장 시 추가한다.

셋째, LLMRec 공개 Netflix subset의 데이터 sparsity로 인해 cold-item Recall 측정이 제한될 가능성이 있다 (학습 인터랙션 0인 아이템 비율이 높을 경우 LightGCN backbone이 추천 자체를 못 함). 이 경우 long-tail 효과는 졸업논문에서 ML-10M + attribute-aware backbone(VBPR/MMGCN)으로 재검증한다.

넷째, Centroid 기반 임베딩 갱신은 prompt-time 표준 통합의 상한선 근사이며, 실제 LLM이 표준 코드만 출력할 때 동일 효과가 나타나는지는 졸업논문 단계 sLLM 검증으로 보완한다.

참고문헌 (핵심)

1. Wei, W., Ren, X., Tang, J., et al. (2024). *LLMRec: Large Language Models with Graph Augmentation for Recommendation*. Proc. WSDM '24.
2. Malitesta, D., et al. (2025). *How Powerful are LLMs to Support Multimodal Recommendation? A Reproducibility Study of LLMRec*. Proc. RecSys '25.
3. Schema.org. *Movie - Schema.org Type*. <https://schema.org/Movie>
4. EIDR. *Entertainment Identifier Registry — ISO 26324-based content identifier system*. <https://www.eidr.org/>
5. ISO 3166-1 (2020). *Codes for the representation of names of countries — Part 1: Country code*. International Organization for Standardization.
6. ISO 639-1 (2002). *Codes for the representation of names of languages — Part 1: Alpha-2 code*. International Organization for Standardization.
7. IETF (2009). *BCP 47 / RFC 5646: Tags for Identifying Languages*.